




**BRAINSIGHT AI**

# BrainSight-AI

Proyecto de clasificación de etapas de Alzheimer usando imágenes MRI y Redes Neuronales Convolucionales.

@autora:

Natalie Pilkington González



urbānīel  
gamjeps

tor

Chaparral regional Institute  
"L'Esper" de l'intégration  
et about tout l'esp. en

Deep learning with CNN

Direct report on project results with  
support for internal and external  
project to the development of the domain.

My Geology

Classroom and field of  
geology with the use of  
technology.



botlot

off a public library  
resources and they  
also to the public.

AI Accelerator

AI Accelerator

Amnical Initiative

One's with the program in  
the field of research for  
the program of the field.

## Descripción del proyecto

El proyecto se estructura en torno a cuatro componentes principales:



- **Big Data:** Utilización de dataset con imágenes MRI.
- **Deep Learning con CNN:** Implementación del modelo TinyVGG16.
- **AI Agents:** Desarrollo de los agentes de recomendación.
- **Implementación:** uso de Streamlit para la implementación de aplicaciones.

**Objetivo principal:** mejorar la **detección temprana** de la enfermedad de Alzheimer, que es crucial para una intervención y un tratamiento eficaces.

# Big Data

El **dataset** utilizado para este proyecto es “Best Alzheimer’s MRI Dataset” de Kaggle. Los detalles clave incluyen:

- Un total de 11.520 **imágenes MRI** de pacientes con o sin Alzheimer de alta calidad
- **Etiquetas:** Datos etiquetados en función de varias etapas de la enfermedad de Alzheimer.
- **Equilibrio:** contiene una mezcla de MRIs axiales reales y sintéticos y todas las clases están representadas de manera equilibrada.



# Clasificación de las etapas de la enfermedad de Alzheimer

El dataset cuenta con 4 clases que clasifican las siguientes etapas de la enfermedad de Alzheimer:

- **Alzheimer Leve:** Signos tempranos de deterioro cognitivo.
- **Alzheimer Moderado:** Dificultades notables en las actividades diarias.
- **Sin Alzheimer:** Función cognitiva normal.
- **Alzheimer muy leve:** Cambios sutiles que pueden no ser evidentes.

## Alzheimer's disease



Mild  
Impairment



Moderate  
Impairment



No Mild  
Impairment



Very Mild  
Impairment

# Almacenamiento de datos con AWS S3



El dataset está almacenado en un **S3 bucket** en la nube de **AWS**:

- Se accede mediante las credenciales temporales suministradas por AWS IAM en el laboratorio de AWS Academy.
- Se extrae y se guarda en Google Drive para su acceso mediante un cuaderno de Google Colab

A screenshot of the Amazon S3 console. The breadcrumb navigation at the top shows the path: Amazon S3 > Buckets > alzheimer-mri-dataset > alz-dataset.zip. The left sidebar contains a list of navigation options under 'Amazon S3', including 'Buckets de uso general', 'Buckets de directorio', 'Buckets de tablas', 'Concesiones de acceso', 'Puntos de acceso', 'Puntos de acceso del objeto', 'Lambda', 'Puntos de acceso de varias regiones', 'Operaciones por lotes', and 'Analizador de acceso de IAM para S3'. The main content area is titled 'Información general sobre el objeto' and displays the following details:

- Propietario:** awslabsc0w4642944t1666346050
- Región de AWS:** EE.UU. Este (Norte de Virginia) us-east-1
- Última modificación:** 21 Feb 2025 10:16:34 AM CET
- Tamaño:** 71.5 MB
- Tipo:** zip
- Clave:** alz-dataset.zip
- URI DE S3:** s3://alzheimer-mri-dataset/alz-dataset.zip
- Nombre de recurso de Amazon (ARN):** arn:aws:s3:::alzheimer-mri-dataset/alz-dataset.zip
- Etiqueta de entidad (Etag):** 23920e9743cb30bd79503a7660b5b165-5
- URL del objeto:** https://alzheimer-mri-dataset.s3.us-east-1.amazonaws.com/alz-dataset.zip



# Amazon CloudWatch

**CloudWatch**

Favoritos y recientes

Paneles

- Operaciones de inteligencia artificial [Vista previa](#)
- Alarmas** ▲ 🔍 ⌵
  - [En modo alarma](#)
  - Todas las alarmas
  - Facturación
- Registros [Nuevo](#)

✓ Se ha creado correctamente la alarma Alarma Facturación AWS Academy.
[Ver alarma](#)
✕

## Alarmas (1)

☐ Ocultar alarmas de Auto Scaling
 

Borrar selección ↺

Crear alarma compuesta

Acciones ▾

Crear alarma

Estado de las acciones: C... ▾

Estado de la alarma: en ... ▾

Tipo de alarma: cualquiera ▾

<input type="checkbox"/>	Nombre ▾	Estado ▾	Última actualización del estado (UTC) ▾	Condiciones
<input type="checkbox"/>	<a href="#">Alarma Facturación AWS Academy</a>	<span style="color:red;">▲ En modo alarma</span>	2025-02-23 19:01:04	EstimatedCharges <= 2! dentro de 6 horas





## GAN para suplir escasez de datos

Si bien el dataset para el entrenamiento (train) era extenso y equilibrado, el utilizado para probar el modelo una vez entrenado (test) era bastante mas reducido y desequilibrado.

Debido a ello y a la **dificultad para encontrar MRI cerebrales reales** sobre Alzheimer, por cuestiones de confidencialidad de los pacientes, creé una red generativa adversarias (**GAN**). Las GAN se emplean para generar imágenes sintéticas de resonancia magnética, que ayudan a **aumentar y equilibrar las clases del dataset**.


Este enfoque **mejora la capacidad del modelo** para aprender y generalizar a partir de datos reales limitados.



# Generación de datos sintéticos con WGAN

Se creó una **WGAN** (Wasserstein Generative Adversarial) para generar imágenes sintéticas con las que **testear el modelo clasificador** de imágenes MRI una vez entrenado.

- Introduce mejoras frente a GAN tradicional como superar '*Modo Colapso*' o el '*Gradient Penalty*'.
- Se usaron un millar de imágenes seleccionadas aleatoriamente del dataset de prueba (test) para entrenar el modelo con 100 épocas.
- Una vez entrenado, se guardaron los modelos **generator** y **critic** (equivalente a discriminator en WGAN) en formato h5.
- Usando el modelo generator.h5 se generaron **300 imágenes sintéticas** de calidad que fueron utilizadas para probar el modelo en la aplicación de Streamlit.



---

# Pre-procesamiento de datos y entrenamiento del modelo

Dependencias y módulos utilizados:

- Uso de **Pytorch** como librería de Machine Learning.
- Uso de **Jupyter Notebooks** para el entrenamiento y la predicción.
- Uso del módulo **transforms** de **torchvision** para redimensionar las imágenes a 128x128 píxeles y convertirlas a tensores de Pytorch.
- Modelo entrenado guardado en formato **.pt**
- Visualización de **métricas** de precisión y pérdida

The Jupyter logo is centered on the right side of the slide. It features the word "jupyter" in a dark grey, lowercase, sans-serif font. The text is enclosed within a large, orange, stylized arc that resembles a wide smile or a partial circle. Four dark grey circles of varying sizes are positioned around the logo: one at the top left, one at the top right, one at the bottom left, and one at the bottom right, creating a balanced, geometric composition.

jupyter

---

# Deep Learning con CNN

El proyecto utiliza la arquitectura **TinyVGG16**, versión compacta de la arquitectura VGG16 para clasificación imágenes, adecuada para aplicaciones donde se requiere un **modelo ligero y eficiente**, como dispositivos con recursos limitados.

- Varios bloques de **capas convolucionales** (con filtros 3x3) seguidos de capas con función de activación **ReLU**. El número de filtros en cada bloque aumenta gradualmente.
- Capas de **max pooling** (2x2) para reducir la dimensionalidad espacial después de cada bloque convolucional.
- **Capas totalmente conectadas** a todas las neuronas de la capa anterior, seguidas de una capa de salida con la función de activación apropiada para la tarea de clasificación (softmax).
- Funciones de **pérdida y optimizador**: cross-entropy loss y Adam optimizer



# Métricas de rendimiento: Matrices de Confusión

## Entrenamiento (Train)

- Casi perfecta clasificación en todas las clases.
- Ejemplo: Para Mild Impairment, de 2560 muestras, solo 1 fue mal clasificada.




## Prueba (Test)

- Más errores de clasificación en comparación con el entrenamiento.
- Ejemplo: Moderate Impairment tuvo 12 clasificaciones incorrectas.



# Métricas de rendimiento: Precisión vs Pérdida



## Métricas: Train vs Test

Conjunto	Loss	Accuracy	Precision	Recall	F1-Score
Entrenamiento	0.0039	99.90%	0.9990	0.9990	0.9990
Prueba	0.1574	95.47%	0.9563	0.9547	0.9548

## Interpretación datos

- Rendimiento excepcional en entrenamiento (99.90% de accuracy): indica que ha aprendido bien estructura datos.
- En prueba, la precision sufre una ligera caída hasta el 95.47%.

## Conclusión

- El modelo tiene un rendimiento muy alto, aunque muestra signos de sobrajuste.
- Se puede mejorar su generalización ajustando la regularización o aumentando el dataset.

# Agentes de IA para recomendaciones médicas



## Agente de chatbot

La aplicación Brainsight AI cuenta con un agente de chatbot que se especializa en la enfermedad de Alzheimer y brinda respuestas a preguntas médicas específicas.



## Agente de recomendación

La aplicación también incluye un agente de recomendación que ofrece asesoramiento médico personalizado en función de los resultados de la clasificación, utilizando el modelo Gemini de Google para brindar información.

# Implementación con Streamlit



## Detector de Alzheimer con IA

Clasificación de etapas de Alzheimer a partir de imágenes de resonancia magnética (MRI)

Suba una imagen MRI para detectar la etapa del Alzheimer.

Drag and drop file here  
Limit 200MB per file • JPG, JPEG, PNG

Browse files

La aplicación Brainsight AI se implementa utilizando **Streamlit**, un potente marco para crear aplicaciones web. Las características clave incluyen:

- **Carga de usuario:** Permite a los usuarios cargar imágenes de resonancia magnética para su análisis.
- **Salida de predicción:** Proporciona a los usuarios predicciones sobre la etapa de la enfermedad de Alzheimer en función de las imágenes cargadas.
- **Interacción:** Los usuarios pueden interactuar con la app a través del asistente virtual creado con IA.
- **Accesibilidad:** La aplicación está disponible tanto en las instalaciones como en la nube de Streamlit.



# Conclusión y direcciones futuras

El proyecto **Brainsight AI** tiene el potencial de tener un impacto significativo en la detección temprana de la enfermedad de Alzheimer. Los desarrollos futuros pueden incluir:

- Mejoras en el modelo para mejorar la precisión (Uso de modelos pre-entrenados como EfficientNet).
- Ampliación del dataset con resonancias magnéticas más diversas.
- Mayor integración de tecnologías de IA para proporcionar información médica completa.

